

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

o0o



BÁO CÁO HỌC PHẦN

ĐỀ TÀI:

**Phân tích và dự đoán nồng độ CO trong không khí dựa
trên các yếu tố môi trường và dữ liệu cảm biến**

Giảng viên hướng dẫn: TS. Cao Văn Chung

Mã học phần: MAT3533

Môn học: Học máy

Danh sách sinh viên thực hiện:

STT	Họ và tên	MSV	Lớp
1	Phạm Ngọc Linh	23000136	K68A2
2	Trương Thị Yến Nhi	23000148	K68A2

Hà Nội, ngày 11 tháng 05 năm 2026

Mục lục

Danh mục hình ảnh	iii
Danh mục bảng	iv
Mở đầu	1
1 CƠ SỞ LÝ THUYẾT VÀ TIỀN XỬ LÝ DỮ LIỆU	3
1 Kiến thức lý thuyết về các phương pháp	3
1.1 Phương pháp giảm chiều dữ liệu PCA và t-SNE	3
1.1.1 Phân tích thành phần chính (PCA - Principal Component Analysis)	3
1.1.2 t-SNE (t-distributed Stochastic Neighbor Embedding)	4
1.2 Các thuật toán phân cụm (K-Means, GMM)	7
1.2.1 K-Means	7
1.2.2 GMM (Thuật toán cực đại hóa kì vọng)	8
1.3 Các mô hình hồi quy và phân loại	9
1.3.1 Hồi quy tuyến tính (Linear Regression)	9
1.3.2 K-NN (K-nearest neighbor)	11
1.3.3 Gaussian Naive Bayes	12
2 Tiền xử lý dữ liệu	13
2.1 Mô tả cấu trúc dữ liệu gốc	13
2.2 Chuẩn hóa và xử lý dữ liệu lỗi	13
2.3 Chuyển đổi dữ liệu	16
2.4 Mô tả dữ liệu sau chuẩn hóa	17
2 PHÂN TÍCH, TRỰC QUAN HÓA VÀ PHÂN CỤM DỮ LIỆU	18
1 Phân tích và trực quan hóa dữ liệu	18
1.1 Phân tích tham số thống kê và chuẩn hóa dữ liệu	18
1.2 Giảm chiều dữ liệu bằng PCA	20
1.2.1 Phân tích phương sai tích lũy (Explained Variance)	20
1.2.2 Mối tương quan với biến mục tiêu CO(GT)	21
1.2.3 Thống kê các thành phần chính (PCA Statistics)	22
1.3 Giảm chiều dữ liệu bằng t-SNE	22

MỤC LỤC

1.3.1	Kết quả giảm chiều và đánh giá chất lượng	22
1.3.2	Trực quan hóa dữ liệu	23
1.3.3	Phân tích mối quan hệ với biến mục tiêu	24
1.4	So sánh và đánh giá tổng hợp các phương pháp giảm chiều	24
1.4.1	So sánh định lượng	24
1.4.2	Phân tích và đánh giá	25
1.4.3	Nhận xét tổng hợp	25
2	Phân cụm dữ liệu	25
2.1	Phân cụm bằng thuật toán K-Means	26
2.1.1	Xác định số lượng cụm tối ưu (k)	26
2.1.2	Trực quan hóa phân cụm bằng PCA	26
2.1.3	Phân tích đặc điểm các cụm theo $CO(GT)$	27
2.1.4	Kiểm định sự khác biệt giữa các cụm	28
2.2	Phân cụm bằng Gaussian Mixture Model (GMM)	28
2.2.1	Xác định số lượng cụm tối ưu (K)	28
2.2.2	Trực quan hóa phân cụm bằng PCA	29
2.2.3	Phân tích đặc điểm các cụm theo $CO(GT)$	29
3	KẾT QUẢ THỰC NGHIỆM HỒI QUY VÀ PHÂN LOẠI	31
1	Phân tích hồi quy	31
1.1	Phân tích dữ liệu và giảm chiều bằng PCA	31
1.2	So sánh hiệu suất các mô hình hồi quy	32
1.3	Ảnh hưởng của tỉ lệ Train/Validation	32
1.4	Đánh giá hiện tượng overfitting	33
1.5	Phân tích phần dư	34
1.6	Kết luận thực nghiệm	35
2	Chuyển đổi bài toán phân cụm sang phân loại	35
2.1	Phương pháp gán nhãn và tiền xử lý	35
2.2	Kết quả thực nghiệm và so sánh	36
2.3	Đánh giá kết quả	36
2.4	Nhận xét	37
	Kết luận	38
	Tài liệu tham khảo	40

Danh sách hình vẽ

1.1	Biểu đồ phân phối của các đặc trưng trong tập dữ liệu trước khi thực hiện tiền xử lý	14
1.2	Biểu đồ Boxplot quan sát phân phối và biến ngoại lai (Outliers) của các đặc trưng.	15
1.3	Ma trận tương quan	16
2.1	Biểu đồ tỉ lệ phương sai giải thích (Explained Variance Ratio) của PCA .	21
2.2	Biểu đồ tương quan giữa các biến và $CO(GT)$	22
2.3	Trực quan hóa dữ liệu bằng t-SNE theo $CO(GT)$	23
2.4	Mối quan hệ giữa $tSNE1$ và $CO(GT)$	24
2.5	So sánh hiệu quả giữa các phương pháp giảm chiều	25
2.6	Kết quả phân cụm K-Means trong không gian PCA	27
2.7	BIC và Silhouette Score theo số cụm K (GMM)	28
2.8	Kết quả phân cụm GMM trong không gian PCA	29
3.1	So sánh hiệu suất R^2 giữa các mô hình trên dữ liệu gốc và PCA	32
3.2	Chênh lệch hiệu suất train–test của các mô hình	33
3.3	Phân phối phần dư của Linear Regression và KNN Regression	34
3.4	Ảnh hưởng của tỉ lệ Train/Validation đến hiệu suất mô hình	34
3.5	So sánh độ chính xác giữa các mô hình (split 80:20)	36
3.6	Ma trận nhầm lẫn của mô hình tốt nhất	37

Danh sách bảng

2.1	Thông kê mô tả các thuộc tính sau tiền xử lý	19
2.2	So sánh định lượng giữa PCA và t-SNE	24
2.3	Đánh giá chất lượng phân cụm theo số cụm k	26
2.4	Thông kê $CO(GT)$ theo cụm K-Means	27
2.5	Thông kê $CO(GT)$ theo cụm GMM	29
3.1	So sánh hiệu suất giữa Linear Regression và KNN Regression	32
3.2	Quy định ngưỡng giá trị cho các lớp phân loại	35
3.3	So sánh độ chính xác (Accuracy) của các mô hình	36

MỞ ĐẦU

Trong những năm gần đây, ô nhiễm không khí đã trở thành một trong những vấn đề môi trường nghiêm trọng tại nhiều quốc gia trên thế giới, đặc biệt tại các khu vực đô thị và công nghiệp hóa nhanh. Sự gia tăng của các phương tiện giao thông, hoạt động sản xuất công nghiệp và quá trình đô thị hóa đã làm nồng độ các khí độc hại trong không khí ngày càng tăng cao, ảnh hưởng trực tiếp đến sức khỏe con người và chất lượng môi trường sống.

Trong số các chất ô nhiễm phổ biến, khí Carbon Monoxide (CO) là một loại khí độc không màu, không mùi nhưng có khả năng gây ảnh hưởng nghiêm trọng đến hệ hô hấp và tuần hoàn nếu tồn tại ở nồng độ cao trong không khí. Việc giám sát và dự báo nồng độ CO có ý nghĩa quan trọng trong công tác quản lý môi trường, cảnh báo chất lượng không khí và hỗ trợ đưa ra các giải pháp giảm thiểu ô nhiễm.

Cùng với sự phát triển của khoa học dữ liệu và trí tuệ nhân tạo, các phương pháp học máy (Machine Learning) đang được ứng dụng rộng rãi trong lĩnh vực phân tích môi trường nhờ khả năng xử lý dữ liệu lớn, phát hiện quy luật tiềm ẩn và xây dựng mô hình dự báo hiệu quả. Các kỹ thuật như hồi quy, phân loại, phân cụm và giảm chiều dữ liệu cho phép khai thác thông tin từ dữ liệu cảm biến môi trường nhằm hỗ trợ việc phân tích và dự báo chất lượng không khí.

Xuất phát từ thực tế đó, đề tài tập trung nghiên cứu và xây dựng các mô hình học máy để phân tích dữ liệu chất lượng không khí, đặc biệt là dự báo nồng độ khí $CO(GT)$. Trong nghiên cứu này, nhiều phương pháp đã được triển khai và đánh giá, bao gồm:

- Tiền xử lý và chuẩn hóa dữ liệu môi trường;
- Giảm chiều dữ liệu bằng PCA;
- Phân cụm dữ liệu bằng K-Means và Gaussian Mixture Model (GMM);
- Xây dựng mô hình hồi quy bằng Linear Regression và KNN Regression;
- Chuyển đổi bài toán sang phân loại và thực hiện phân loại bằng Naive Bayes và KNN.

Thông qua việc so sánh các mô hình và đánh giá thực nghiệm trên dữ liệu thực tế, đề tài hướng tới mục tiêu tìm ra phương pháp phù hợp nhằm nâng cao hiệu quả dự báo và phân tích chất lượng không khí.

Bố cục của báo cáo gồm các nội dung chính như sau:

- Chương 1: Cơ sở lý thuyết;
- Chương 2: Phân cụm dữ liệu;
- Chương 3: Kết quả thực nghiệm hồi quy và phân loại;
- Phần kết luận và hướng phát triển.

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT VÀ TIỀN XỬ LÝ DỮ LIỆU

1 Kiến thức lý thuyết về các phương pháp

1.1 Phương pháp giảm chiều dữ liệu PCA và t-SNE

1.1.1 Phân tích thành phần chính (PCA - Principal Component Analysis)

PCA là một phương pháp giảm chiều tuyến tính, không giám sát, tìm một hệ trục tọa độ mới sao cho phần lớn phương sai của dữ liệu được tập trung vào một số ít thành phần đầu tiên.

Giả sử dữ liệu có dạng ma trận $X \in \mathbb{R}^{d \times N}$, mỗi cột là một mẫu:

1. Tính vector trung bình:

$$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$$

2. Chuẩn hóa dữ liệu về trung tâm:

$$\hat{x}_n = x_n - \bar{x}$$

3. Tính ma trận hiệp phương sai:

$$S = \frac{1}{N} \hat{X} \hat{X}^T$$

4. Tìm các giá trị riêng λ_i và vector riêng u_i của S , sắp xếp:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$$

5. Chọn k vector riêng đầu, tạo thành ma trận:

$$U_k = (u_1, u_2, \dots, u_k) \in \mathbb{R}^{d \times k}$$

6. Chiếu dữ liệu:

$$Z = U_k^T \hat{X} \in \mathbb{R}^{k \times N}$$

Tỷ lệ phương sai được giữ lại khi chọn k thành phần chính:

$$r_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j}$$

1.1.2 t-SNE (t-distributed Stochastic Neighbor Embedding)

t-SNE là một kỹ thuật giảm chiều phi tuyến, nghĩa là nó không dựa trên các phép biến đổi tuyến tính như PCA (Principal Component Analysis). Thay vào đó, t-SNE tập trung vào việc bảo toàn mối quan hệ lân cận (*local structure*) giữa các điểm dữ liệu trong không gian cao chiều khi chuyển đổi sang không gian thấp chiều.

Các bước xây dựng mô hình t-SNE

Bước 1: Tính toán phân phối xác suất trong không gian gốc

- Tạo phân phối Gaussian cho mỗi điểm dữ liệu.
- Với mỗi điểm dữ liệu x_i , tính khoảng cách Euclidean đến tất cả các điểm khác x_j .
- Sử dụng phân phối Gaussian để chuyển khoảng cách thành xác suất:

$$p_{j|i} = \frac{\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|x_i - x_k\|^2}{2\sigma_i^2}\right)}$$

trong đó:

- $p_{j|i}$ là xác suất để điểm x_i chọn x_j làm láng giềng.
- σ_i là độ lệch chuẩn của phân phối Gaussian tại điểm x_i .

Phần tử số (*numerator*) trong công thức là hàm hạt nhân Gaussian, giúp tạo ra hình dạng chuông của phân phối và đảm bảo khoảng cách được chuyển thành xác suất trong khoảng từ 0 đến 1. Điều này tránh việc các giá trị khoảng cách phụ thuộc vào đơn vị đo lường của dữ liệu.

Độ lệch chuẩn của điểm x_i phụ thuộc vào *perplexity*, tham số này quyết định mức độ mà mô hình sẽ tập trung vào việc ánh xạ các điểm gần nhau hay các điểm xa nhau.

Perplexity trong t-SNE là tham số điều chỉnh mức độ “nhìn xa trông rộng” của thuật toán trong việc xác định hàng xóm của một điểm dữ liệu. Nó đại diện cho số lượng điểm dữ liệu lân cận mà thuật toán xem xét khi tính toán mối quan hệ giữa các điểm.

Xác suất chung p_{ij}

Với n là tổng số điểm dữ liệu đang xét, do:

$$p_{i|j} \neq p_{j|i}$$

nên ta tính xác suất chung bằng cách trung bình hóa:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

Nếu p_{ij} không đối xứng, việc tính toán gradient của hàm mất mát sẽ phức tạp hơn do cần xử lý các xác suất có điều kiện riêng biệt $p_{i|j}$ và $p_{j|i}$.

Bước 2: Tính toán phân phối xác suất trong không gian giảm chiều

- Trong không gian giảm chiều (thường là 2D hoặc 3D), mỗi điểm dữ liệu y_i được ánh xạ từ x_i .
- Sử dụng phân phối t-Student để tính xác suất giữa các điểm y_i và y_j :

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

trong đó:

- q_{ij} là xác suất biểu diễn mức độ tương đồng giữa hai điểm y_i và y_j trong không gian giảm chiều.
- Phân phối t-Student có đuôi dài hơn phân phối Gaussian, giúp giảm hiện tượng các điểm dữ liệu bị dồn quá gần nhau (*crowding problem*).

Bước 3: Tối ưu hóa hàm mất mát

- Sử dụng KL Divergence.
- Để làm cho phân phối q_{ij} gần giống với p_{ij} , ta tối ưu hóa hàm mất mát:

$$KL(P \parallel Q) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

- p_{ij} : phân phối trong không gian gốc (*high-dimensional space*).
- q_{ij} : phân phối trong không gian chiều thấp (*low-dimensional space*).

Tính gradient của hàm mất mát

Khi y_i thay đổi thì chỉ có d_{ij} và d_{ji} thay đổi:

$$d_{ij} = \|y_i - y_j\|^2$$

Gradient của hàm mất mát theo y_i được tính bởi:

$$\frac{\partial C}{\partial y_i} = \sum_j \left(\frac{\partial C}{\partial d_{ij}} + \frac{\partial C}{\partial d_{ji}} \right) (y_i - y_j) = 2 \sum_j \frac{\partial C}{\partial d_{ij}} (y_i - y_j)$$

$$\text{Hàm mất mát } C = \sum_i \sum_j p_{ij} \log p_{ij} - p_{ij} \log q_{ij}$$

$$\frac{\partial C}{\partial d_{ij}} = - \sum_i \sum_j p_{ij} \frac{\partial (\log q_{ij})}{\partial d_{ij}}$$

$$= - \sum_{k \neq l} p_{kl} \frac{\partial (\log q_{kl})}{\partial d_{ij}}$$

$$= - \sum_{k \neq l} p_{kl} \frac{\partial (\log q_{kl} Z - \log Z)}{\partial d_{ij}}$$

$$= - \sum_{k \neq l} p_{kl} \left(\frac{1}{q_{kl} Z} \frac{\partial ((1 + d_{kl}^2)^{-1})}{\partial d_{ij}} - \frac{1}{Z} \frac{\partial Z}{\partial d_{ij}} \right)$$

$$= 2 \frac{p_{ij}}{q_{ij} Z} (1 + d_{ij}^2)^{-2} - 2 \sum_{k \neq l} p_{kl} \frac{(1 + d_{ij}^2)^{-2}}{Z}$$

$$(\because \text{when } k \neq i \cap l \neq j, \frac{\partial ((1 + d_{kl}^2)^{-1})}{\partial d_{ij}} = 0)$$

$$= 2(p_{ij} - q_{ij})(1 + d_{ij}^2)^{-1}$$

$$\frac{\partial C}{\partial y_i} = 4 \sum_j (p_{ij} - q_{ij})(y_i - y_j) (1 + \|y_i - y_j\|^2)^{-1}$$

- Cập nhật vị trí y_i :

Sử dụng thuật toán Gradient Descent để cập nhật:

$$y_i^{(t+1)} = y_i^{(t)} - \eta \frac{\partial C}{\partial y_i}$$

Trong đó:

- η : Learning rate, kiểm soát tốc độ cập nhật.

Điều chỉnh vị trí y_i để giảm giá trị của hàm mất mát C , qua đó cải thiện sự tương đồng giữa phân phối xác suất trong không gian cao chiều và không gian thấp chiều.

1.2 Các thuật toán phân cụm (K-Means, GMM)

1.2.1 K-Means

Cho tập dữ liệu $\{x_n\}_{n=1}^N$, K-Means tìm K tâm cụm $\{\mu_k\}_{k=1}^K$ sao cho tổng bình phương khoảng cách từ mỗi điểm tới tâm cụm gần nhất được tối thiểu hóa:

$$\min_{\{\mu_k\}, \{C_k\}} \sum_{k=1}^K \sum_{x_n \in C_k} \|x_n - \mu_k\|_2^2$$

Trong đó C_k là tập các điểm thuộc cụm k .

Thuật toán lặp

1. Khởi tạo: chọn ngẫu nhiên K tâm ban đầu μ_k (hoặc dùng K-Means++).
2. Bước gán cụm: với mỗi điểm x_n , gán vào cụm gần nhất:

$$c_n = \arg \min_k \|x_n - \mu_k\|_2^2$$

3. Bước cập nhật tâm: với mỗi cụm k , cập nhật:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_n \in C_k} x_n$$

4. Lặp lại bước 2 và bước 3 cho đến khi các tâm cụm hội tụ hoặc không còn thay đổi đáng kể.

Lựa chọn số cụm và đánh giá chất lượng cụm

Chỉ số thường dùng là tổng phương sai trong cụm (SSE – Within-Cluster Sum of Squares):

$$SSE(K) = \sum_{k=1}^K \sum_{x_n \in C_k} \|x_n - \mu_k\|_2^2$$

Khi K tăng, SSE giảm; phương pháp “khuỷu tay” (*elbow*) chọn K tại vị trí độ giảm SSE bắt đầu chậm lại. Các chỉ số khác như Silhouette cũng có thể được dùng để đánh giá chất lượng phân cụm.

1.2.2 GMM (Thuật toán cực đại hóa kì vọng)

Giả sử dữ liệu phân bố thành C cụm, dữ liệu trong mỗi cụm lại có dạng phân phối Gaussian nhiều chiều.

Chú ý: Xác suất của mỗi điểm dữ liệu không chỉ phụ thuộc vào một phân phối Gaussian duy nhất mà chịu tác động kết hợp từ nhiều phân phối Gaussian khác nhau từ mỗi cụm.

⇒ Gọi là Mô hình trộn Gaussian – Gaussian Mixture Model (GMM).

Mục tiêu của GMM là ước lượng tham số phù hợp nhất cho C cụm thông qua phương pháp ước lượng hợp lý cực đại (MLE – Maximum Likelihood Estimation).

Giả thiết của mô hình

Dữ liệu của mỗi cụm tuân theo phân phối Gaussian d chiều với tập tham số:

$$\{(\mu_c, \Sigma_c)\}_{c=1}^C$$

Tồn tại ước lượng ngẫu nhiên $z_c = z_c(x)$:

$$z_c = \begin{cases} 1, & \text{nếu dữ liệu } x \text{ thuộc cụm thứ } c \\ 0, & \text{ngược lại} \end{cases}$$

z_c được coi như một biến ẩn (*latent variable*) vì ta không quan sát trực tiếp được giá trị của nó.

Vì vậy, GMM là mô hình biến ẩn. Xác suất $P(z_c = 1|x)$ giúp ta xác định tham số phân phối của mô hình Gaussian Mixture.

Tập các z_c của mỗi cụm c tạo thành phân phối xác suất:

$$(\pi_1, \pi_2, \dots, \pi_C)$$

với:

$$\pi_k = P(z_k = 1|x)$$

Một xác suất hỗn hợp tác động lên một điểm dữ liệu x được tính theo công thức Bayes

như sau:

$$\begin{aligned} p(\mathbf{x}) &= \sum_{c=1}^C p(z_c) p(\mathbf{x} \mid z_c) = \sum_{c=1}^C p(z_c = 1) p(\mathbf{x} \mid \mu_c, \Sigma_c) \\ &= \sum_{c=1}^C \pi_c p(\mathbf{x} \mid \mu_c, \Sigma_c) = \sum_{c=1}^C \pi_c \mathcal{N}(\mathbf{x} \mid \mu_c, \Sigma_c) \end{aligned}$$

1.3 Các mô hình hồi quy và phân loại

1.3.1 Hồi quy tuyến tính (Linear Regression)

Hồi quy tuyến tính (linear regression) là một thuật toán hồi quy mà đầu ra là một hàm số tuyến tính của đầu vào. Đây là thuật toán đơn giản nhất trong nhóm các thuật toán học có giám sát.

Tổng quát, nếu mỗi điểm dữ liệu được mô tả bởi một vector đặc trưng d chiều $x \in \mathbb{R}^d$, thì đầu ra được biểu diễn bởi:

$$y = w_1 x_1 + w_2 x_2 + \dots + w_d x_d = x^T w$$

Trong đó:

$$x = [x_1, x_2, \dots, x_d]^T$$

là vector đặc trưng đầu vào,

$$w = [w_1, w_2, \dots, w_d]^T$$

là vector trọng số (weight vector), và y là đầu ra dự đoán.

Sau khi xây dựng mô hình dự đoán đầu ra, ta cần một phép đánh giá mức độ sai lệch giữa giá trị thực tế y và giá trị dự đoán $\hat{y}$. Sai số được xác định bởi:

$$\frac{1}{2} e^2 = \frac{1}{2} (y - \hat{y})^2 = \frac{1}{2} (y - x^T w)^2$$

Với N là số lượng dữ liệu trong tập huấn luyện, việc tìm mô hình tốt nhất tương đương với việc tìm w sao cho hàm mất mát đạt giá trị nhỏ nhất:

$$L(w) = \frac{1}{2N} \sum_{i=1}^N (y_i - x_i^T w)^2$$

Hàm số $L(w)$ chính là hàm mất mát (loss function) của mô hình hồi quy tuyến tính với tham số $\theta = w$. Ta luôn mong muốn sự mất mát là nhỏ nhất, điều này tương đương

với bài toán tối ưu:

$$w^* = \arg \min_w L(w)$$

Trong đó w^* là nghiệm tối ưu cần tìm.

Nhận thấy rằng hàm mất mát $L(w)$ có gradient tại mọi w . Gradient của hàm số này được xác định như sau:

$$\nabla_w L(w) = \frac{1}{N} X(X^T w - y)$$

Khi gradient bằng không, ta thu được phương trình chuẩn (normal equation):

$$\nabla_w L(w) = 0 \iff XX^T w = Xy$$

Nghiệm của bài toán tối ưu là:

$$w = (XX^T)^\dagger Xy$$

Trong đó $(XX^T)^\dagger$ là giả nghịch đảo Moore–Penrose của ma trận XX^T .

Hàm dự đoán đầu ra của hồi quy tuyến tính thường được bổ sung thêm hệ số điều chỉnh (bias) b :

$$f(x) = x^T w + b$$

Nếu $b = 0$, đường thẳng hoặc siêu phẳng hồi quy sẽ luôn đi qua gốc tọa độ. Việc thêm hệ số b giúp mô hình linh hoạt hơn.

Ta có thể đưa hệ số điều chỉnh vào vector trọng số bằng cách thêm một đặc trưng cố định $x_0 = 1$:

$$y = x^T w + b = w_1 x_1 + w_2 x_2 + \dots + w_d x_d + b x_0 = \bar{x}^T \bar{w}$$

Trong đó:

$$\bar{x} = [x_0, x_1, \dots, x_d]^T$$

$$\bar{w} = [b, w_1, w_2, \dots, w_d]^T$$

Kỹ thuật này được gọi là bias trick (thủ thuật gộp hệ số điều chỉnh).

Khi đó, nghiệm tối ưu của bài toán trở thành:

$$\bar{w} = \arg \min_{\bar{w}} \frac{1}{2N} \|y - \bar{X}^T \bar{w}\|_2^2 = (\bar{X} \bar{X}^T)^\dagger \bar{X} y$$

1.3.2 K-NN (K-nearest neighbor)

K lân cận (K-nearest neighbor hay KNN) là một trong những thuật toán học có giám sát đơn giản nhất. Mọi tính toán được thực hiện tại pha kiểm tra. KNN có thể được áp dụng vào các bài toán phân loại và hồi quy. KNN còn được gọi là một thuật toán lười học (*lazy learning*), *instance-based learning*, hoặc *memory-based learning*.

KNN là thuật toán đi tìm đầu ra của một điểm dữ liệu mới chỉ dựa trên thông tin của K điểm dữ liệu gần nhất trong tập huấn luyện.

Với KNN, mọi điểm trong tập huấn luyện đều được mô hình mô tả một cách chính xác. Việc này khiến hiện tượng *overfitting* dễ xảy ra với KNN.

Các bước của phương pháp K-NN có thể mô tả như sau:

1. Với mỗi x chưa thấy ở đầu vào (các phần tử trong tập Validation).
2. Tính khoảng cách d_i từ x đến các x_i trong tập Training, sau đó lập thành một mảng khoảng cách.
3. Sắp xếp các khoảng cách này theo thứ tự tăng dần, đồng thời lưu lại chỉ số tương ứng của các phần tử ban đầu trong mảng d_i .
4. Tìm ra K chỉ số của các phần tử x_i trong tập Training ứng với các khoảng cách d_i nhỏ nhất.
5. Tính đầu ra dự đoán:

$$y_{\text{pred}} = \frac{\sum y_i}{K}$$

Như vậy, ta cần xây dựng hàm tính khoảng cách giữa x và các x_i .

- Trong trường hợp biến đơn (không gian có $d = 1$ chiều), ta sử dụng khoảng cách:

$$|x - x_i|$$

Trong Python có thể dùng: `abs(x - xi)`

- Trong trường hợp $d > 1$, ta sử dụng khoảng cách Euclid.

Khoảng cách Euclid từ một điểm z tới một điểm x_i trong tập huấn luyện được định nghĩa bởi:

$$\|z - x_i\|_2$$

Người ta thường dùng bình phương khoảng cách Euclid để tránh phép tính căn bậc hai:

$$\|z - x_i\|_2^2$$

Việc bình phương này không ảnh hưởng tới thứ tự của các khoảng cách. Ta có:

$$\|z - x_i\|_2^2 = (z - x_i)^T (z - x_i) = \|z\|_2^2 + \|x_i\|_2^2 - 2x_i^T z$$

Để tìm ra x_i gần với z nhất, số hạng đầu tiên có thể được bỏ qua. Hơn nữa, nếu có nhiều điểm dữ liệu trong tập kiểm tra, các giá trị:

$$\|x_i\|_2^2$$

có thể được tính trước và lưu vào bộ nhớ. Khi đó, ta chỉ cần tính các tích vô hướng:

$$x_i^T z$$

1.3.3 Gaussian Naive Bayes

Numeric (x_i): Trường dữ liệu x_i là các giá trị số thực (ví dụ: tuổi, độ pH máu, điểm thi, ...).

Giả thiết: Trong mỗi phân lớp k , dữ liệu x_i tuân theo phân bố chuẩn với kỳ vọng μ_{ki} và phương sai σ_{ki}^2 :

$$x_i \sim \mathcal{N}(\mu_{ki}, \sigma_{ki}^2)$$

Xác suất có điều kiện:

$$p(x_i | k) = p(x_i | \mu_{ki}, \sigma_{ki}^2) = \frac{1}{\sqrt{2\pi\sigma_{ki}^2}} \exp\left(-\frac{(x_i - \mu_{ki})^2}{2\sigma_{ki}^2}\right) \quad (12)$$

Ước lượng tham số: Bộ tham số $\theta = \{\mu_{ki}, \sigma_{ki}^2\}$ được xác định bằng phương pháp Cực đại hóa hàm độ tin cậy (Maximum Likelihood Estimation - MLE):

$$(\hat{\mu}_{ki}, \hat{\sigma}_{ki}^2) = \arg \max_{\mu_{ki}, \sigma_{ki}^2} \prod_{n=1}^N p\left(x_i^{(n)} | \mu_{ki}, \sigma_{ki}^2\right) \quad (13)$$

Giải thích ý nghĩa: Trong (12), ta sử dụng hàm mật độ xác suất thay vì hàm phân bố vì mục tiêu là tìm lớp k sao cho khả năng xảy ra của x_i là cao nhất. Các giá trị tham số được tính toán trực tiếp trên tập huấn luyện (Training set) theo công thức:

$$\begin{aligned}\mu_{ki} &= \frac{1}{N_k} \sum_{x^{(m)} \in \text{class } k} x_i^{(m)} \\ \sigma_{ki}^2 &= \frac{1}{N_k} \sum_{x^{(m)} \in \text{class } k} (x_i^{(m)} - \mu_{ki})^2\end{aligned}\tag{14}$$

Ký hiệu:

- $x^{(m)} \in \mathcal{X}$: Các mẫu thuộc tập huấn luyện.
- N_k : Số lượng mẫu thuộc lớp k .

2 Tiền xử lý dữ liệu

2.1 Mô tả cấu trúc dữ liệu gốc

Tập dữ liệu ban đầu gồm 9357 mẫu dữ liệu với 15 thuộc tính mô tả các thông số liên quan đến chất lượng không khí và điều kiện môi trường. Mỗi dòng dữ liệu tương ứng với một thời điểm ghi nhận theo giờ của hệ thống cảm biến.

Cấu trúc dữ liệu bao gồm ba nhóm thuộc tính chính:


- Nhóm thông tin thời gian: gồm ngày và thời gian thu thập dữ liệu.
- Nhóm thông số chất lượng không khí: bao gồm các giá trị nồng độ của các chất khí như CO, NOx, NO₂, Benzene và Hydrocarbon.
- Nhóm dữ liệu cảm biến và môi trường: bao gồm phản hồi từ các cảm biến PT08.S1 đến PT08.S5 cùng với các thông số nhiệt độ, độ ẩm tương đối và độ ẩm tuyệt đối.

Trong bài toán dự đoán, thuộc tính CO(GT) được sử dụng làm biến đầu ra, còn các thuộc tính còn lại được sử dụng làm biến đầu vào cho mô hình học máy.

Ngoài ra, dữ liệu ban đầu còn tồn tại một số giá trị thiếu được đánh dấu bằng giá trị -200 và sự chênh lệch lớn về miền giá trị giữa các thuộc tính, do đó cần thực hiện các bước tiền xử lý trước khi huấn luyện mô hình.

2.2 Chuẩn hóa và xử lý dữ liệu lỗi

Trước khi tiến hành các bước làm sạch, nhóm đã thực hiện phân tích phân phối của toàn bộ các đặc trưng trong tập dữ liệu. Việc trực quan hóa này giúp nhận diện các vấn đề về nhiễu, giá trị thiếu và sự chênh lệch đơn vị đo giữa các cảm biến.



Hình 1.1: Biểu đồ phân phối của các đặc trưng trong tập dữ liệu trước khi thực hiện tiền xử lý

Quan sát Hình 1.1, ta có thể thấy rõ sự hiện diện của các giá trị nhiễu (các cột cao bất thường tại một giá trị cụ thể - thường là do mã hóa giá trị thiếu -200). Ngoài ra, các biến như $NOx(GT)$ và $NO_2(GT)$ có biên độ giá trị rất khác biệt so với các biến nhiệt độ hay độ ẩm, khẳng định sự cần thiết của bước chuẩn hóa dữ liệu (Scaling).

Xử lý giá trị thiếu (Missing Values)


Các giá trị thiếu trong tập dữ liệu được mã hóa dưới dạng -200. Nhóm tiến hành chuyển đổi các giá trị này về dạng giá trị rỗng NaN để thuận tiện cho việc xử lý.

Phương pháp xử lý:

- Đối với các thuộc tính dạng số, nhóm sử dụng giá trị trung vị (*Median*) để thay thế nhằm giảm ảnh hưởng của các giá trị ngoại lệ.
- Đối với các thuộc tính phân loại (nếu có), sử dụng giá trị xuất hiện nhiều nhất (*Mode*) để thay thế.

Kết quả: Sau khi xử lý, tổng số lượng giá trị thiếu trong tập dữ liệu bằng 0, đảm bảo tính toàn vẹn và độ tin cậy cho quá trình thực nghiệm.

Xử lý giá trị ngoại lệ (Outliers)



Hình 1.2: Biểu đồ Boxplot quan sát phân phối và biến ngoại lai (Outliers) của các đặc trưng.

Thông qua biểu đồ Boxplot (Hình minh họa), dữ liệu ban đầu xuất hiện nhiều điểm dị biệt tại các cảm biến hóa học.

Phương pháp xử lý: Nhóm áp dụng phương pháp IQR (*Interquartile Range*). Các giá trị nằm ngoài khoảng:

$$[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$$

được điều chỉnh về ngưỡng gần nhất (*Capping*). Phương pháp này giúp hạn chế ảnh hưởng của ngoại lệ nhưng vẫn giữ nguyên số lượng bản ghi của tập dữ liệu.

Chuẩn hóa dữ liệu (Scaling)

Do các thuộc tính trong tập dữ liệu có đơn vị đo khác nhau như nhiệt độ, độ ẩm và nồng độ khí, nhóm sử dụng kỹ thuật chuẩn hóa Z-score Standardization.

Sau chuẩn hóa, dữ liệu có:

$$\mu = 0, \quad \sigma = 1$$

Điều này giúp các thuật toán như PCA, K-Means và Hồi quy hoạt động ổn định hơn, đồng thời cải thiện tốc độ hội tụ của mô hình.

2.3 Chuyển đổi dữ liệu

Hai cột Date và Time ban đầu được kết hợp thành thuộc tính kiểu Datetime.


Từ thuộc tính thời gian tổng hợp, nhóm trích xuất thêm các đặc trưng:

- Day – Ngày
- Month – Tháng
- Year – Năm
- Hour – Giờ

Trong đó, thuộc tính Hour đặc biệt quan trọng vì nồng độ khí CO thường thay đổi mạnh theo chu kỳ giao thông trong ngày.

Lựa chọn đặc trưng

Thuộc tính NMHC (GT) được loại bỏ khỏi mô hình do tỷ lệ giá trị thiếu vượt quá 90%, không đảm bảo độ tin cậy cho quá trình phân tích.



Hình 1.3: Ma trận tương quan

Dựa trên ma trận tương quan (*Correlation Heatmap*), các thuộc tính có mối liên hệ mạnh với biến mục tiêu $CO(GT)$ như:

$$C_6H_6(GT), \quad PT08.S1(CO)$$

được ưu tiên giữ lại để phục vụ cho quá trình dự đoán.

2.4 Mô tả dữ liệu sau chuẩn hóa

Sau quá trình tiền xử lý, tập dữ liệu đã sẵn sàng cho các bước phân tích và xây dựng mô hình.

Cấu trúc dữ liệu cuối cùng

Tập dữ liệu sau xử lý bao gồm:

- 9471 bản ghi
- 16 thuộc tính

Trong đó đã bao gồm các thuộc tính thời gian được trích xuất từ biến `Datetime` như: `Day`, `Month`, `Year` và `Hour`.

Phân tích tương quan dữ liệu

Sau khi chuẩn hóa dữ liệu bằng phương pháp *Standard Scaling*, nhóm tiến hành phân tích mức độ tương quan giữa các thuộc tính thông qua ma trận tương quan (*Correlation Matrix*).

Từ hình 1.3 có thể nhận thấy biến mục tiêu $CO(GT)$ có tương quan thuận tương đối mạnh với thuộc tính $C_6H_6(GT)$ và nhóm cảm biến thuộc họ `PT08`. Điều này cho thấy các cảm biến hóa học phụ trợ có khả năng phản ánh sự thay đổi nồng độ khí CO trong môi trường.

Ngoài ra, các thuộc tính sau chuẩn hóa đã có cùng thang đo, giúp giảm sự chênh lệch giá trị giữa các biến và hỗ trợ tốt hơn cho các thuật toán học máy trong quá trình huấn luyện mô hình.

Kết quả phân tích cho thấy việc sử dụng dữ liệu cảm biến để dự đoán nồng độ khí CO là hoàn toàn khả thi và có ý nghĩa thực tiễn cao trong các hệ thống giám sát chất lượng không khí.

CHƯƠNG 2: PHÂN TÍCH, TRỰC QUAN HÓA VÀ PHÂN CỤM DỮ LIỆU

1 Phân tích và trực quan hóa dữ liệu

1.1 Phân tích tham số thống kê và chuẩn hóa dữ liệu

Sau quá trình tiền xử lý, tập dữ liệu thu được gồm 9471 mẫu dữ liệu và 14 thuộc tính. Để đánh giá đặc điểm phân bố của dữ liệu trước khi thực hiện PCA, tiến hành thống kê các tham số mô tả cơ bản như:

- Giá trị trung bình (`mean`);
- Độ lệch chuẩn (`std`);
- Giá trị nhỏ nhất (`min`);
- Các phân vị 25%, 50%, 75%;
- Giá trị lớn nhất (`max`).

Kết quả thống kê mô tả được trình bày trong Bảng 2.1. Quan sát bảng thống kê cho thấy các thuộc tính có sự khác biệt đáng kể về miền giá trị và mức độ biến động.

Bảng 2.1: Thống kê mô tả các thuộc tính sau tiền xử lý

Thuộc tính	Mean	Std	Min	25%	50%	75%	Max
PT08.S1(CO)	1096.08	206.01	647.00	943.00	1063.00	1218.00	1630.50
C6H6(GT)	9.80	6.66	0.10	4.60	8.20	13.50	26.85
PT08.S2(NMHC)	936.43	256.33	383.00	744.00	909.00	1102.00	1639.00
NO _x (GT)	217.47	144.97	2.00	113.00	180.00	281.50	534.25
PT08.S3(NO _x)	827.27	228.47	322.00	667.00	806.00	957.00	1392.00
NO ₂ (GT)	111.20	40.51	17.00	86.00	109.00	132.00	201.00
PT08.S4(NO ₂)	1454.36	330.77	628.00	1246.00	1463.00	1658.00	2276.00
PT08.S5(O ₃)	1017.49	381.51	221.00	744.50	963.00	1250.00	2008.25
T	18.29	8.60	-1.90	12.10	17.80	24.00	41.85
RH	49.25	16.87	9.20	36.70	49.60	61.70	88.70
AH	1.02	0.39	0.18	0.75	1.00	1.29	2.10
Day	15.70	8.90	1.00	8.00	16.00	23.00	31.00
Month	6.25	3.47	1.00	3.00	6.00	9.00	12.00
Hour	11.36	6.99	0.00	5.00	11.00	17.00	23.00

Từ kết quả thống kê có thể nhận thấy các thuộc tính cảm biến khí có miền giá trị khá lớn. Cụ thể, thuộc tính PT08.S4(NO₂) có giá trị trung bình khoảng 1454.36 với giá trị lớn nhất đạt 2276, trong khi thuộc tính PT08.S5(O₃) có giá trị trung bình khoảng 1017.49. Ngược lại, thuộc tính AH chỉ có giá trị trung bình khoảng 1.02. Điều này cho thấy dữ liệu tồn tại sự chênh lệch đáng kể về thang đo giữa các thuộc tính.

Bên cạnh đó, các thuộc tính như NO_x(GT), PT08.S5(O₃) và PT08.S2(NMHC) có độ lệch chuẩn tương đối lớn, phản ánh mức độ biến động mạnh của dữ liệu môi trường theo thời gian. Thuộc tính nhiệt độ T dao động trong khoảng từ $-1.9^{\circ}C$ đến $41.85^{\circ}C$, còn độ ẩm tương đối RH nằm trong khoảng từ 9.2 đến 88.7.

Do sự khác biệt lớn về miền giá trị giữa các thuộc tính, nếu đưa trực tiếp dữ liệu vào PCA thì các biến có giá trị lớn sẽ ảnh hưởng mạnh hơn đến phương sai tổng thể của dữ liệu. Vì vậy, dữ liệu được chuẩn hóa bằng phương pháp **StandardScaler** trước khi thực hiện PCA.

Phương pháp này thực hiện chuẩn hóa dữ liệu theo công thức:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

- x là giá trị ban đầu;

- μ là giá trị trung bình của thuộc tính;
- σ là độ lệch chuẩn của thuộc tính.

Sau khi chuẩn hóa, các thuộc tính được đưa về cùng thang đo với giá trị trung bình xấp xỉ 0 và độ lệch chuẩn xấp xỉ 1. Điều này giúp tăng hiệu quả của PCA, hạn chế ảnh hưởng của các thuộc tính có giá trị lớn và cải thiện chất lượng phân cụm dữ liệu.

Hình 1.3 trình bày heatmap thống kê mô tả của các thuộc tính sau tiền xử lý dữ liệu.

Quan sát heatmap cho thấy các thuộc tính cảm biến khí có giá trị trung bình và miền dao động lớn hơn đáng kể so với các thuộc tính thời gian như Day, Month và Hour. Ngoài ra, một số thuộc tính có độ lệch chuẩn cao phản ánh sự thay đổi mạnh của chất lượng không khí theo từng thời điểm đo.

Nhìn chung, sau bước tiền xử lý và chuẩn hóa, tập dữ liệu đã sẵn sàng cho quá trình giảm chiều dữ liệu bằng PCA và phân cụm dữ liệu ở các phần tiếp theo.

1.2 Giảm chiều dữ liệu bằng PCA


Sau giai đoạn tiền xử lý, tập dữ liệu bao gồm nhiều thuộc tính có mối quan hệ tương quan phức tạp. Để tối ưu hóa hiệu suất huấn luyện mô hình và giảm thiểu nguy cơ quá khớp (overfitting), phương pháp Phân tích thành phần chính (Principal Component Analysis – PCA) được áp dụng nhằm trích xuất các đặc trưng quan trọng nhất và giảm số chiều dữ liệu.

1.2.1 Phân tích phương sai tích lũy (Explained Variance)

Kết quả thực nghiệm PCA cho thấy khả năng nén thông tin hiệu quả của các thành phần chính đầu tiên:

- PC1 (Thành phần chính 1) giải thích khoảng 78.90% phương sai của toàn bộ dữ liệu.
- PC2 đóng góp thêm 13.95%.
- PC3 đóng góp thêm 2.92%.

Như vậy, chỉ với 3 thành phần chính đầu tiên, mô hình đã giữ lại hơn 95% lượng thông tin của tập dữ liệu gốc gồm 14 biến. Việc giảm số chiều từ 14 xuống 3 không chỉ giúp đơn giản hóa không gian dữ liệu mà còn loại bỏ đáng kể các yếu tố nhiễu và các thuộc tính dư thừa.




Hình 2.1: Biểu đồ tỉ lệ phương sai giải thích (Explained Variance Ratio) của PCA

1.2.2 Môi tương quan với biến mục tiêu CO(GT)

Song song với PCA, phân tích tương quan giữa các biến đầu vào và biến mục tiêu $CO(GT)$ cho thấy các mối quan hệ đáng chú ý:

- Tương quan thuận mạnh: $C6H6(GT)$ (0.817), $PT08.S2(NMHC)$ (0.810), $PT08.S1(CO)$ (0.783). Điều này cho thấy các hợp chất hữu cơ dễ bay hơi và phản hồi từ cảm biến oxit kim loại đóng vai trò quan trọng trong việc dự đoán nồng độ CO.
- Tương quan nghịch: $PT08.S3(NOx)$ (-0.680), thể hiện mối quan hệ tỉ lệ nghịch đáng kể với nồng độ CO.
- Yếu tố môi trường: Các biến như nhiệt độ (T), độ ẩm tương đối (RH) và độ ẩm tuyệt đối (AH) có hệ số tương quan rất thấp (dưới 0.03), cho thấy ảnh hưởng trực tiếp không đáng kể đến biến mục tiêu.



Hình 2.2: Biểu đồ tương quan giữa các biến và CO(GT)

1.2.3 Thống kê các thành phần chính (PCA Statistics)

Sau khi biến đổi sang không gian PCA, dữ liệu được chuẩn hóa với giá trị trung bình xấp xỉ bằng 0. Trong đó, thành phần PC1 có độ lệch chuẩn lớn nhất (588.18), cho thấy đây là trục chứa nhiều thông tin phân tán và quan trọng nhất trong tập dữ liệu.

Kết luận: Việc lựa chọn 3 thành phần chính là tối ưu, vừa đảm bảo giữ lại hơn 95% thông tin của dữ liệu gốc, vừa giúp giảm đáng kể độ phức tạp tính toán. Đây là cơ sở quan trọng để cải thiện hiệu suất và độ chính xác của các mô hình dự báo ở các bước tiếp theo.

1.3 Giảm chiều dữ liệu bằng t-SNE

Để khai thác các cấu trúc phi tuyến tiềm ẩn trong dữ liệu, kỹ thuật *t-Distributed Stochastic Neighbor Embedding* (t-SNE) được sử dụng nhằm giảm số chiều dữ liệu và trực quan hóa tập dữ liệu nhiều chiều lên không gian hai chiều. Phương pháp này tập trung bảo toàn quan hệ lân cận giữa các điểm dữ liệu, từ đó giúp làm rõ cấu trúc phân bố và khả năng hình thành các cụm dữ liệu liên quan đến biến mục tiêu $CO(GT)$.

1.3.1 Kết quả giảm chiều và đánh giá chất lượng


Sau khi áp dụng t-SNE, dữ liệu được ánh xạ về không gian hai chiều ($tSNE1, tSNE2$). Kết quả phân tích cho thấy:

- Độ tin cậy (Trustworthiness Score): đạt 0.9992, cho thấy cấu trúc lân cận trong không gian gốc được bảo toàn rất tốt trong không gian giảm chiều. Điều này đảm bảo rằng các điểm dữ liệu gần nhau trong không gian ban đầu vẫn duy trì được mức độ tương đồng sau khi chiếu xuống 2D.
- Phân bố dữ liệu: các điểm dữ liệu phân bố rộng trong không gian hai chiều, đồng thời hình thành các vùng tập trung rõ rệt. Điều này phản ánh sự tồn tại của các cấu trúc nhóm tiềm ẩn trong dữ liệu môi trường.

Giá trị trustworthiness cao cho thấy phép chiếu t-SNE duy trì hiệu quả cấu trúc cục bộ, qua đó đảm bảo tính tin cậy của kết quả trực quan hóa.

1.3.2 Trực quan hóa dữ liệu


Kết quả trực quan hóa cho thấy dữ liệu không phân bố ngẫu nhiên mà hình thành các cụm và vùng chuyển tiếp liên tục theo giá trị $CO(GT)$. Các điểm có nồng độ CO cao có xu hướng tập trung thành từng khu vực riêng biệt, trong khi các vùng có nồng độ thấp phân bố rải rác hơn. Điều này cho thấy tồn tại cấu trúc phi tuyến rõ rệt giữa các đặc trưng đầu vào và biến mục tiêu.



Hình 2.3: Trực quan hóa dữ liệu bằng t-SNE theo $CO(GT)$

1.3.3 Phân tích mối quan hệ với biến mục tiêu

Xét mối quan hệ giữa thành phần $tSNE1$ và biến mục tiêu $CO(GT)$, kết quả cho thấy tồn tại xu hướng phụ thuộc cục bộ. Cụ thể, khi giá trị $tSNE1$ tăng, nồng độ CO có xu hướng biến thiên cùng chiều trong một số vùng dữ liệu nhất định. Điều này cho thấy t-SNE không chỉ giúp trực quan hóa mà còn phần nào bảo toàn thông tin liên quan đến cấu trúc biến mục tiêu trong không gian giảm chiều.



Hình 2.4: Mối quan hệ giữa $tSNE1$ và $CO(GT)$

1.4 So sánh và đánh giá tổng hợp các phương pháp giảm chiều


Sau khi triển khai hai phương pháp giảm chiều là PCA và t-SNE, các kết quả thực nghiệm được tổng hợp nhằm đánh giá hiệu quả của từng phương pháp theo các tiêu chí khác nhau, bao gồm khả năng bảo toàn phương sai và khả năng duy trì cấu trúc lân cận của dữ liệu.

1.4.1 So sánh định lượng

Bảng dưới đây trình bày kết quả so sánh giữa PCA và t-SNE dựa trên các chỉ số đặc trưng:

Phương pháp	Phương sai tích lũy	Trustworthiness
PCA (3 thành phần)	95.77%	—
t-SNE (2 thành phần)	—	0.9992

Bảng 2.2: So sánh định lượng giữa PCA và t-SNE



Hình 2.5: So sánh hiệu quả giữa các phương pháp giảm chiều

1.4.2 Phân tích và đánh giá

Kết quả thực nghiệm cho thấy hai phương pháp có định hướng tối ưu khác nhau:

- PCA: tập trung vào tối đa hóa phương sai được giữ lại trong không gian giảm chiều. Với 3 thành phần chính, PCA giữ lại 95.77% thông tin của dữ liệu gốc, cho thấy khả năng nén dữ liệu hiệu quả và giảm độ phức tạp tính toán. Điều này phù hợp cho các mô hình học máy cần đầu vào ổn định và có cấu trúc tuyến tính rõ ràng.
- t-SNE: tập trung vào bảo toàn cấu trúc lân cận giữa các điểm dữ liệu. Chỉ số Trustworthiness đạt 0.9992 cho thấy khả năng duy trì quan hệ cục bộ rất cao. Ngoài ra, t-SNE thể hiện ưu thế rõ rệt trong việc trực quan hóa và phát hiện các cấu trúc phi tuyến trong dữ liệu.

1.4.3 Nhận xét tổng hợp

Từ kết quả trên, có thể thấy PCA và t-SNE phục vụ hai mục tiêu khác nhau trong phân tích dữ liệu: PCA phù hợp cho giảm chiều phục vụ mô hình dự báo, trong khi t-SNE phù hợp cho trực quan hóa và phân tích cấu trúc dữ liệu. Việc kết hợp cả hai phương pháp giúp vừa đảm bảo hiệu quả tính toán, vừa hỗ trợ đánh giá trực quan tính chất phân bố của dữ liệu trong không gian đặc trưng.

2 Phân cụm dữ liệu

Trong giai đoạn này, đề tài triển khai các thuật toán học máy không giám sát nhằm khám phá cấu trúc tiềm ẩn trong dữ liệu môi trường. Việc phân cụm giúp nhận diện các

trạng thái chất lượng không khí đặc trưng, hỗ trợ cho các phân tích chuyên sâu và các mô hình dự báo ở các bước tiếp theo. Đề tài tiến hành thử nghiệm song song hai thuật toán phổ biến là K-Means và Gaussian Mixture Model (GMM) nhằm tìm ra phương án phân tách dữ liệu phù hợp nhất.

2.1 Phân cụm bằng thuật toán K-Means

K-Means là thuật toán phân cụm dựa trên khoảng cách, trong đó dữ liệu được chia thành k cụm sao cho các điểm trong cùng cụm có mức độ tương đồng cao nhất. Trong nghiên cứu này, thuật toán được áp dụng trên 10 đặc trưng đầu vào bao gồm các chỉ số cảm biến khí (PT08.S1, C6H6, NOx, NO2,...) và các yếu tố khí tượng như nhiệt độ (T), độ ẩm (RH) và độ ẩm tuyệt đối (AH).

Kết quả thực nghiệm cho thấy dữ liệu được phân tách tốt nhất thành 2 cụm, tương ứng với hai chế độ (regimes) chất lượng không khí khác nhau.

2.1.1 Xác định số lượng cụm tối ưu (k)

Số cụm tối ưu được xác định là $k = 2$ dựa trên đồng thời Silhouette Score và Davies-Bouldin Index (DBI).

Mô hình được huấn luyện với k từ 2 đến 7 và đánh giá theo hai chỉ số:

- **Silhouette Score:** đo mức độ tương đồng trong cùng cụm và mức độ tách biệt giữa các cụm. Giá trị càng lớn càng tốt.
- **Davies-Bouldin Index (DBI):** đo mức độ phân tán nội cụm so với khoảng cách giữa các cụm. Giá trị càng nhỏ càng tốt.


Bảng 2.3: Đánh giá chất lượng phân cụm theo số cụm k

k	Silhouette Score	DBI
2	0.3193	1.2635
3	0.2437	1.3683
4	0.2416	1.2780
5	0.2211	1.3469
6	0.2198	1.2876
7	0.2199	1.3254

2.1.2 Trực quan hóa phân cụm bằng PCA

Do dữ liệu có số chiều lớn, PCA được sử dụng để giảm xuống không gian 2 chiều nhằm trực quan hóa kết quả phân cụm.

Hai thành phần chính đầu tiên giải thích khoảng **76.6%** phương sai của dữ liệu (52.1% và 24.5%), đảm bảo khả năng bảo toàn thông tin tương đối tốt.



Hình 2.6: Kết quả phân cụm K-Means trong không gian PCA

Trong không gian PCA, hai cụm được phân tách tương đối rõ ràng, tuy nhiên vẫn tồn tại một mức độ chồng lấn nhỏ tại ranh giới, phản ánh giới hạn của mô hình K-Means trong việc xử lý dữ liệu có phân bố phức tạp.

2.1.3 Phân tích đặc điểm các cụm theo $CO(GT)$

Để đánh giá ý nghĩa thực tế của các cụm, tiến hành phân tích phân bố $CO(GT)$ theo từng cụm.

Bảng 2.4: Thống kê $CO(GT)$ theo cụm K-Means

Cụm	Số lượng	Mean	Std
Cụm 0	3,262	1.0189	0.8880
Cụm 1	6,209	-0.5353	0.5283

Kết quả cho thấy cụm 0 có giá trị trung bình $CO(GT)$ cao hơn đáng kể so với cụm 1, đồng thời độ biến thiên cũng lớn hơn, phản ánh mức độ ô nhiễm cao hơn trong nhóm này.

2.1.4 Kiểm định sự khác biệt giữa các cụm

Để kiểm tra sự khác biệt có ý nghĩa thống kê giữa các cụm, kiểm định ANOVA một yếu tố được thực hiện trên biến $CO(GT)$.

$$p\text{-value} < 0.001$$

Kết quả cho thấy sự khác biệt giữa các cụm là có ý nghĩa thống kê, khẳng định rằng K-Means đã phân tách được các nhóm quan trắc có đặc trưng khác nhau về mức độ ô nhiễm không khí.

2.2 Phân cụm bằng Gaussian Mixture Model (GMM)


Gaussian Mixture Model (GMM) là phương pháp phân cụm dựa trên mô hình xác suất, trong đó dữ liệu được giả định sinh ra từ hỗn hợp nhiều phân phối Gaussian với các ma trận hiệp phương sai khác nhau. So với K-Means, GMM linh hoạt hơn nhờ khả năng mô hình hóa các cụm có hình dạng elip và phương sai không đồng nhất.

2.2.1 Xác định số lượng cụm tối ưu (K)

Số cụm tối ưu được xác định là $K = 6$ dựa trên tiêu chí BIC kết hợp Silhouette Score.

Mô hình được đánh giá theo:

- **BIC:** giảm mạnh khi K tăng từ 2 đến 4 và tiếp tục giảm đến $K = 6$, cho thấy $K = 6$ là lựa chọn tối ưu theo tiêu chí mô hình xác suất.
- **Silhouette Score:** mặc dù giá trị cao nhất tại $K = 2$, nhưng $K = 6$ vẫn giữ được mức phân tách hợp lý và cho phép mô tả chi tiết hơn cấu trúc dữ liệu.




Hình 2.7: BIC và Silhouette Score theo số cụm K (GMM)

2.2.2 Trực quan hóa phân cụm bằng PCA

PCA được sử dụng để giảm dữ liệu xuống không gian 2 chiều nhằm trực quan hóa kết quả phân cụm.

Ba thành phần chính đầu tiên giải thích khoảng **81.04%** phương sai dữ liệu, cho thấy mức độ bảo toàn thông tin cao.



Hình 2.8: Kết quả phân cụm GMM trong không gian PCA

Trong không gian PCA, các cụm có sự phân tách rõ hơn so với trực giác ban đầu, tuy nhiên vẫn tồn tại chồng lấn nhẹ tại biên, phản ánh đặc trưng soft clustering của GMM.

2.2.3 Phân tích đặc điểm các cụm theo CO(GT)

Phân tích thống kê cho thấy sự khác biệt rõ rệt giữa các cụm:

Bảng 2.5: Thống kê $CO(GT)$ theo cụm GMM

Cụm	Mean $CO(GT)$	Nhiệt độ (T)	Trạng thái
Cluster 3	1.12	10.56°C	Không khí sạch nhất
Cluster 2	1.64	19.26°C	Ô nhiễm nhẹ
Cluster 0	1.95	30.06°C	Ô nhiễm trung bình (mùa nóng)
Cluster 1	1.96	8.02°C	Ô nhiễm trung bình (mùa lạnh)
Cluster 5	3.35	22.80°C	Ô nhiễm nặng
Cluster 4	4.14	12.21°C	Ô nhiễm nghiêm trọng nhất

Nhận xét:

- Cluster 4 thể hiện mức độ ô nhiễm cao nhất và độ biến thiên lớn nhất.

- Một số cụm có cùng mức $CO(GT)$ nhưng khác biệt rõ về nhiệt độ, cho thấy GMM khai thác tốt cả yếu tố khí tượng.
- Các cụm ô nhiễm cao đồng thời có giá trị cảm biến hóa học lớn, phù hợp với xu hướng tăng của NOx và C_6H_6 .

CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM HỒI QUY VÀ PHÂN LOẠI

1 Phân tích hồi quy

Phần này trình bày toàn bộ kết quả thực nghiệm của bài toán hồi quy dự báo nồng độ khí $CO(GT)$, với hai mô hình được lựa chọn là Hồi quy tuyến tính (Linear Regression) và K-Nearest Neighbors Regression (KNN).

Các mô hình được đánh giá theo ba khía cạnh chính:

- Ảnh hưởng của giảm chiều dữ liệu bằng PCA
- Ảnh hưởng của tỉ lệ Train/Validation
- Khả năng tổng quát hóa và hiện tượng overfitting
- Phân tích sai số (residual analysis)

Tất cả thực nghiệm được thực hiện trên hai dạng dữ liệu:

- Dữ liệu gốc sau tiền xử lý (14 đặc trưng)
- Dữ liệu sau giảm chiều bằng PCA (7 thành phần chính)

1.1 Phân tích dữ liệu và giảm chiều bằng PCA

Sau quá trình tiền xử lý, tập dữ liệu có kích thước (9471 x 14) và không còn giá trị thiếu, đảm bảo tính đầy đủ cho mô hình học máy.

Phương pháp PCA được áp dụng nhằm giảm chiều dữ liệu xuống còn 7 thành phần chính, với mục tiêu: (i) giảm nhiễu, (ii) giảm đa cộng tuyến, và (iii) tăng hiệu quả tính toán.

Kết quả phân tích PCA cho thấy các biến cảm biến khí như $PT08.S1(CO)$, $C6H6(GT)$, $PT08.S2(NMHC)$, NO_x và NO_2 có mức đóng góp lớn vào các thành phần chính đầu tiên. Ngoài ra, các biến thời gian (Hour, Month, Day) cũng có ảnh hưởng đáng kể, cho thấy dữ liệu mang đồng thời đặc trưng môi trường và tính chu kỳ theo thời gian.

Điều này khẳng định rằng cấu trúc dữ liệu có sự tương quan mạnh giữa các biến cảm biến.


1.2 So sánh hiệu suất các mô hình hồi quy

Hiệu suất mô hình được đánh giá thông qua hệ số xác định R^2 và sai số RMSE.

Bảng 3.1: So sánh hiệu suất giữa Linear Regression và KNN Regression

Mô hình	Dữ liệu	RMSE	R^2 Test	R^2 Train
Linear Regression	Original	≈ 0.55	0.827	0.822
Linear Regression	PCA	≈ 0.67	0.746	0.733
KNN Regression	Original	0.368–0.383	0.868	0.895
KNN Regression	PCA	0.396–0.403	0.848	0.880

Để trực quan hóa kết quả, Hình 3.1 thể hiện sự so sánh hệ số R^2 giữa các mô hình.



Hình 3.1: So sánh hiệu suất R^2 giữa các mô hình trên dữ liệu gốc và PCA

Nhận xét chính:

- KNN Regression đạt hiệu suất cao nhất trong toàn bộ thực nghiệm, chứng tỏ khả năng mô hình hóa tốt quan hệ phi tuyến trong dữ liệu.
- Linear Regression suy giảm rõ rệt khi áp dụng PCA, cho thấy mô hình tuyến tính phụ thuộc mạnh vào không gian đặc trưng ban đầu.
- PCA giúp giảm chiều dữ liệu hiệu quả nhưng đánh đổi bằng sự suy giảm nhẹ hiệu suất dự đoán.

1.3 Ảnh hưởng của tỉ lệ Train/Validation


Các mô hình được đánh giá trên ba tỉ lệ chia dữ liệu: 80/20, 70/30 và 60/40 nhằm kiểm tra tính ổn định.

Kết quả phân tích cho thấy:

- Linear Regression có hiệu suất ổn định nhưng không cải thiện theo tỉ lệ chia.
- KNN Regression duy trì độ ổn định tốt, với biến động nhỏ giữa các cấu hình.
- Tỉ lệ 80/20 cho kết quả tối ưu do cân bằng tốt giữa dữ liệu huấn luyện và kiểm tra.

1.4 Đánh giá hiện tượng overfitting

Mức độ overfitting được xác định thông qua chênh lệch giữa hiệu suất tập huấn luyện và tập kiểm tra.



Hình 3.2: Chênh lệch hiệu suất train-test của các mô hình


Kết quả cho thấy:

- Linear Regression có chênh lệch train-test rất nhỏ nhưng hiệu suất thấp hơn đáng kể so với KNN.
- KNN Regression có chênh lệch khoảng 2–3%, cho thấy mô hình không bị overfitting nghiêm trọng.
- Không có cải thiện đáng kể từ regularization đối với mô hình tuyến tính.


Nhìn chung, KNN thể hiện sự cân bằng tốt giữa bias và variance, phù hợp với đặc trưng phi tuyến của dữ liệu.

1.5 Phân tích phần dư

Phân tích phần dư được sử dụng để đánh giá mức độ phù hợp của mô hình và kiểm tra giả định sai số.



Hình 3.3: Phân phối phần dư của Linear Regression và KNN Regression



Hình 3.4: Ảnh hưởng của tỉ lệ Train/Validation đến hiệu suất mô hình

Phân tích kết quả:

- Phần dư của cả hai mô hình phân bố quanh 0 và gần tuân theo phân phối chuẩn.
- Không quan sát thấy cấu trúc rõ ràng giữa phần dư và giá trị dự đoán, cho thấy mô hình không vi phạm giả định tuyến tính nghiêm trọng.
- Tuy nhiên, Linear Regression thể hiện phương sai sai số lớn hơn tại vùng giá trị dự đoán cao.
- KNN Regression cho phân bố phần dư mượt hơn, phản ánh khả năng mô hình hóa phi tuyến tốt hơn.

1.6 Kết luận thực nghiệm

Tổng hợp toàn bộ kết quả thực nghiệm, có thể rút ra các kết luận chính:

- KNN Regression là mô hình có hiệu suất tốt nhất trên cả dữ liệu gốc và PCA.
- Linear Regression phù hợp nhưng hạn chế trong việc mô hình hóa quan hệ phi tuyến.
- PCA giúp giảm chiều hiệu quả nhưng gây suy giảm nhẹ hiệu suất dự đoán.

Do đó, cấu hình tối ưu cho bài toán dự báo $CO(GT)$ trong nghiên cứu này là KNN Regression trên dữ liệu gốc với tỉ lệ chia 80/20.

2 Chuyển đổi bài toán phân cụm sang phân loại

2.1 Phương pháp gán nhãn và tiền xử lý

Trong phần này, bài toán dự báo nồng độ khí $CO(GT)$ được chuyển đổi từ bài toán hồi quy sang bài toán phân loại. Cách tiếp cận này nhằm thay thế việc ước lượng giá trị liên tục bằng việc dự đoán các nhóm giá trị có ý nghĩa tương đối, từ đó đơn giản hóa không gian đầu ra và cải thiện khả năng học của mô hình.

Biến mục tiêu được rời rạc hóa thành 4 lớp dựa trên phương pháp chia theo phân vị, đảm bảo các lớp có số lượng mẫu tương đối cân bằng. Các khoảng giá trị tương ứng được trình bày trong Bảng dưới đây:

Bảng 3.2: Quy định ngưỡng giá trị cho các lớp phân loại

Lớp (Class)	Khoảng giá trị	Ý nghĩa thực tế
0	0.1 $\rightarrow$ 1.2	Thấp
1	1.2 $\rightarrow$ 1.8	Trung bình thấp
2	1.8 $\rightarrow$ 2.6	Trung bình cao
3	2.6 $\rightarrow$ 11.9	Cao


Song song với đó, dữ liệu đầu vào được giảm chiều bằng PCA từ 12 đặc trưng xuống còn 4 thành phần chính. Kết quả cho thấy bốn thành phần đầu tiên giải thích phần lớn phương sai của dữ liệu, đảm bảo khả năng giữ lại thông tin quan trọng phục vụ cho bài toán phân loại.

2.2 Kết quả thực nghiệm và so sánh

Hai mô hình phân loại được sử dụng gồm Gaussian Naive Bayes và K-Nearest Neighbors (KNN), được đánh giá trên cả dữ liệu gốc và dữ liệu sau giảm chiều PCA, với ba tỷ lệ chia train/test khác nhau.

Bảng 3.3: So sánh độ chính xác (Accuracy) của các mô hình

Dataset	Split	Naive Bayes	KNN
Original	80:20	0.6802	0.8000
Original	70:30	0.6928	0.7994
Original	60:40	0.6907	0.7865
PCA	80:20	0.6058	0.7156
PCA	70:30	0.6094	0.7072
PCA	60:40	0.6141	0.7047



Hình 3.5: So sánh độ chính xác giữa các mô hình (split 80:20)


2.3 Đánh giá kết quả

Kết quả thực nghiệm cho thấy KNN luôn đạt hiệu suất cao hơn Naive Bayes trong tất cả các thiết lập. Điều này có thể giải thích bởi việc Naive Bayes giả định tính độc lập có điều kiện giữa các đặc trưng, trong khi dữ liệu thực tế thường tồn tại tương quan mạnh giữa các biến quan sát.

Bên cạnh đó, việc giảm chiều bằng PCA làm giảm nhẹ hiệu suất của cả hai mô hình,

do một phần thông tin phân biệt giữa các lớp bị loại bỏ trong quá trình nén không gian đặc trưng.

Phân tích từ ma trận nhầm lẫn cho thấy các lớp biên (lớp 0 và lớp 3) được phân loại tốt hơn, trong khi các lớp trung gian có mức độ nhầm lẫn cao hơn do sự chồng lấn trong phân bố dữ liệu.



Hình 3.6: Ma trận nhầm lẫn của mô hình tốt nhất

2.4 Nhận xét

Phương pháp chuyển đổi bài toán hồi quy sang phân loại cho kết quả khả quan, trong đó KNN trên dữ liệu gốc thể hiện hiệu suất tốt nhất. PCA giúp giảm độ phức tạp tính toán nhưng đánh đổi bằng sự suy giảm nhẹ độ chính xác.

Kết luận

KẾT LUẬN

1. Những kết quả đạt được

Đề tài đã hoàn thành các mục tiêu nghiên cứu đề ra liên quan đến việc phân tích dữ liệu cảm biến môi trường và xây dựng mô hình dự báo nồng độ khí CO trong không khí. Các kết quả chính đạt được bao gồm:

Tiền xử lý và phân tích dữ liệu: Đã xây dựng được quy trình xử lý dữ liệu cảm biến thô, bao gồm xử lý giá trị thiếu (giá trị -200), chuẩn hóa dữ liệu bằng Z-score, đồng thời áp dụng các kỹ thuật giảm chiều như PCA và t-SNE nhằm trực quan hóa và khai thác cấu trúc tiềm ẩn của dữ liệu.

Hiệu quả phân cụm: Thuật toán Gaussian Mixture Model (GMM) cho thấy khả năng phân tách dữ liệu thành các nhóm trạng thái ô nhiễm khác nhau, phản ánh rõ sự biến thiên của nồng độ CO theo các điều kiện môi trường. Kết quả phân cụm góp phần hỗ trợ việc hiểu rõ hơn cấu trúc dữ liệu trước khi xây dựng mô hình dự đoán.

Hiệu suất dự báo: Trong bài toán hồi quy và phân loại, mô hình K-Nearest Neighbors (KNN) đạt hiệu quả tốt hơn so với các mô hình tuyến tính và Naive Bayes. Đối với bài toán hồi quy, KNN đạt hệ số xác định $R^2 \approx 0.868$, cho thấy khả năng mô hình hóa quan hệ phi tuyến giữa các đặc trưng môi trường và nồng độ CO.

2. Những hạn chế của nghiên cứu

Bên cạnh các kết quả đạt được, nghiên cứu vẫn tồn tại một số hạn chế nhất định:

Về dữ liệu: Dữ liệu sử dụng được thu thập tại một địa điểm và trong một khoảng thời gian giới hạn, do đó khả năng khái quát hóa sang các khu vực địa lý hoặc điều kiện khí hậu khác còn hạn chế.

Về mô hình: Các mô hình như KNN và Naive Bayes chưa khai thác được đặc trưng chuỗi thời gian của dữ liệu. Ngoài ra, việc giảm chiều bằng PCA mặc dù giúp giảm độ phức tạp tính toán nhưng đồng thời làm mất một phần thông tin quan trọng, dẫn đến sự suy giảm nhẹ về hiệu suất so với dữ liệu gốc.

Về triển khai thực tế: Nghiên cứu mới dừng ở mức mô phỏng trên dữ liệu tĩnh, chưa triển khai hệ thống dự báo thời gian thực, do đó chưa đánh giá được đầy đủ khả năng ứng dụng trong môi trường thực tế.

3. Hướng phát triển tương lai

Từ những hạn chế trên, một số hướng phát triển tiếp theo được đề xuất như sau:

Cải tiến mô hình: Áp dụng các mô hình học sâu dành cho dữ liệu chuỗi thời gian như LSTM hoặc GRU nhằm cải thiện khả năng dự báo dài hạn và khai thác tốt hơn tính phụ thuộc theo thời gian.

Mở rộng đặc trưng: Tích hợp thêm các biến môi trường bên ngoài như mật độ giao thông, tốc độ gió, hướng gió và độ ẩm nhằm nâng cao khả năng giải thích và độ chính xác của mô hình.

Triển khai hệ thống: Xây dựng hệ thống dự báo chất lượng không khí theo thời gian thực dưới dạng ứng dụng hoặc nền tảng web, cung cấp cảnh báo sớm cho người dùng và hỗ trợ ra quyết định..

Tài liệu tham khảo

- [1] T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2009.
- [2] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [3] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- [4] A. Ng, *Machine Learning Lecture Notes*, Stanford University, 2017.
- [5] Scikit-learn Developers, *Scikit-learn: Machine Learning in Python*, <https://scikit-learn.org>, truy cập 2026.
- [6] UCI Machine Learning Repository, *Air Quality Data Set*, <https://archive.ics.uci.edu/ml>, truy cập 2026.
- [7] J. MacQueen, *Some Methods for Classification and Analysis of Multivariate Observations*, Proceedings of 5th Berkeley Symposium, 1967.
- [8] D. Reynolds, *Gaussian Mixture Models*, Encyclopedia of Biometrics, Springer, 2009.
- [9] Vũ Hữu Tiệp, *Machine Learning cơ bản*, Nhà xuất bản Khoa học và Kỹ thuật, Việt Nam.
- [10] Cao Văn Chung, *Tài liệu học máy*, Tài liệu giảng dạy nội bộ / Đại học Khoa học Tự Nhiên, Việt Nam.